

OR Note 3

数学分析: Weierstrass theorem

若 $f(x)$ 在闭区间 $[a, b]$ 上连续, 则 $f(x)$ 在 $[a, b]$ 上必定取得最大值和最小值.

$$f(x) = I_{[0,1]}(x) = \begin{cases} 0 & x \in [0,1] \\ +\infty & \text{otherwise} \end{cases} \quad \text{indicator function}$$

Defn (实值函数) 映射 $f: \mathbb{R}^n \rightarrow \mathbb{R}$

(广义实值函数) 映射 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}} := \mathbb{R} \cup \{\pm\infty\}$

(适当函数 proper function) 给定 f 为实值函数 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$, 非空集合 Ω .

① 若存在 $x \in \Omega$ 使得 $f(x) < +\infty$, 且


② 任意 $x \in \Omega$, $f(x) > -\infty$

则称 f 为适当函数.

Defn (下水平集 lower level set) 给定 f 为实值函数 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$,

$$C_\alpha := \{x \mid f(x) \leq \alpha\}$$

称为 f 的下水平集



Defn (上图 epigraph) 给定 f 为实值函数 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$,

$$\text{epi } f := \{(x, t) \in \mathbb{R}^{n+1} \mid f(x) \leq t\}$$

称为 f 的上图.


Thm (下半连续函数与闭函数) 设 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$, 以下命题等价.

① $f(x)$ 任意 α -下水平集是闭集

② $f(x)$ 是下半连续的

③ $f(x)$ 是闭函数.

OR Note 3



$$\text{epi } f = \{(x, t) \in \mathbb{R}^{n+1}, f(x) \leq t\}$$

拓展: 定义域非空, 目标函数非连续

Then (Weierstrass theorem) $f: \Omega \rightarrow (-\infty, +\infty]$ 适当且闭的函数. 如果:

① $\text{dom } f = \{x \in \Omega, f(x) < +\infty\}$ 是有界的.

② 存在一个 r 下水平集: $C_r = \{x \in \Omega, f(x) \leq r\}$ 是非空且有界的.

③ f 是强制的 (coersive): $\forall \|x^k\| \rightarrow +\infty, x^k \in \Omega$, 有 $\lim_{k \rightarrow \infty} f(x^k) = +\infty$

以上三条中任意一个成立, 则优化问题

的最小值点集 $\{x \in \Omega \mid f(x) \leq \min_{y \in \Omega} f(y)\}$ 是非空且紧的. (无穷问题)

Proof: (2) \Rightarrow 结论. 反证法证下确界存在. 设下确界: $\tau := \inf f(x) = -\infty$

则存在点列 $\{x^k\}_{k=1}^{\infty} \subset C_r$, 使得 $\lim_{k \rightarrow \infty} f(x^k) = \tau = -\infty$. 因为 C_r 有界.

则 $\{x^k\}$ 存在聚点, 记为 x^* .

因为 f 是下半连续的, 所以 f 的上图是闭集. 由于 $(x^*, \tau) \in \text{epi } f \Rightarrow f(x^*) \leq \tau = -\infty$, 与函数实值性矛盾. 故 $\tau > -\infty$.

由于 τ 是下确界, 且 $f(x^*) \leq \tau \Rightarrow f(x^*) = \tau$

根据前述定理, 下水平集 C_r 是闭集, 由 C_r 有界


\Rightarrow 最小值点集为紧集

(1) \Rightarrow (2) \Rightarrow 结论. (1) $\Rightarrow \text{dom } f$ 有界. 由于 f 是适当函数, $\exists x_0 \in \Omega$ 使得 $f(x_0) < +\infty$ 令 $r = f(x_0)$. 由 $\text{dom } f$ 有界, $\Rightarrow C_r \subset \text{dom } f$ 有界且非空 \Rightarrow (2) 成立 \Rightarrow 结论.


(3) \Rightarrow (2) \Rightarrow 结论. 假设 C_r 无界. $\exists \{x^k\} \subset C_r$, s.t. $\lim_{k \rightarrow \infty} \|x^k\| = +\infty$. 根据 f 的强制性, 有 $\lim_{k \rightarrow \infty} f(x^k) = +\infty$. 由于 C_r 是下水平集, $\forall x \in C_r, f(x) \leq r$, 与 $\lim_{k \rightarrow \infty} f(x^k) = +\infty$ 矛盾. \Rightarrow (2) 成立 \Rightarrow 结论.

①. 三个条件都立保证 $f(x)$ 最小值不能无穷远处取到.

②. 可行域可以无界, 只需要保证 (2): 即 $f(x)$ 为闭适当函数, 且下水平集非空且有界.



$$f(x) = \max(x, 0)$$



e.g. $f(x) = x^2 \quad x \in \mathbb{R} \Rightarrow$ 强凸函数
 $f(x) = e^{-x} \quad x \in \mathbb{R} \Rightarrow$ 下水平集无界.
 $f(x) = \mathbb{I}_{(0,1)} \quad x \in \mathbb{R} \Rightarrow \text{dom} f = (0,1)$ 有界.

唯一性:

- ① 若最优点是唯一, 所有算法最终收敛到 x^* , 此时, 可以较不同算法达到 x^* 的收敛速度.
- ② 若最优点不唯一, 但最优值唯一, 此时, 可以较不同算法达到最优值的收敛速度.

最优性理论

Defn (下降方向) 对于可微函数 f , 如果存在向量 d 满足

$$\nabla f(x)^T d < 0$$

那么称 d 为 f 在点 x 处的一个下降方向.

如果 f 在 x 处存在一个下降方向 d , 那么对于任意 $T > 0$, 存在 $t \in (0, T]$, 使得

$$f(x + td) < f(x)$$

线搜索方法

$$\text{Iterate: } x^{k+1} = x^k + \alpha_k d^k$$

d^k : 搜索方向, α_k : 步长 (学习率)

精确搜索步长: $\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha) = f(x^k + \alpha d^k)$

① 计算量大, 实际中很少用

② 实际中用非精确搜索步长, 仅要求 $\phi(\alpha)$ 满足某些不等式性质

梯度下降法

- ① 无约束优化问题
- ② 只需知道一阶导
- ③ 每步迭代成本很低

$$\begin{aligned}\text{考虑 } \phi(\alpha) &= f(x^k + \alpha d^k) \\ &= f(x^k) + \nabla f(x^k)^T (x^k + \alpha d^k - x^k) + O(\alpha^2 \|d^k\|^2) \\ &= f(x^k) + \alpha \nabla f(x^k)^T d^k + O(\alpha^2 \|d^k\|^2)\end{aligned}$$

→ 也称为最速下降法

当 α 足够小时, $d^k = -\nabla f(x^k)$ 会使得函数的下降速度最快

$$\phi(\alpha) - f(x^k) \approx \alpha \nabla f(x^k)^T d^k \leq \alpha \|\nabla f(x^k)\| \|d^k\|$$

→ 若 $\|\nabla f(x^k)\| = \|d^k\|$

Thm: 考虑二次, 正定 (对称) 问题 $f(x) = \frac{1}{2} x^T A x - b^T x$

① 精确搜索步长: $\alpha_k = \frac{\|\nabla f(x^k)\|_2^2}{\nabla f(x^k)^T A \nabla f(x^k)}$

② Q-线性收敛: $\|x^{k+1} - x^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right) \|x^k - x^*\|_A$

其中, λ_1, λ_n 对应 \min, \max eigenvalue of A . $\|x\|_A = \sqrt{x^T A x}$

Proof: 梯度: $\nabla f(x^k) = A x^k - b$

迭代: $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$

精确搜索步长: $\alpha^* = \arg \min_{\alpha > 0} \phi(\alpha) = f(x^k + \alpha d^k)$

$$\begin{aligned}\phi(\alpha) &= f(x^k + \alpha d^k) = f(x^k - \alpha \nabla f(x^k)) \\ &= \frac{1}{2} (x^k - \alpha \nabla f(x^k))^T A (x^k - \alpha \nabla f(x^k)) - b^T (x^k - \alpha \nabla f(x^k)) \\ &= \frac{1}{2} (x^{kT} A x^k - 2\alpha x^{kT} A \nabla f(x^k) + \alpha^2 \nabla f(x^k)^T A \nabla f(x^k)) - b^T x^k + \alpha b^T \nabla f(x^k)\end{aligned}$$

对 $\phi(\alpha)$ 求导

$$\phi'(\alpha) = -x^{kT} A \nabla f(x^k) + \alpha \nabla f(x^k)^T A \nabla f(x^k) + b^T \nabla f(x^k) = 0$$

$$A = A^T$$

$$\Rightarrow \alpha \nabla f(x^k)^T A \nabla f(x^k) = x^{kT} A \nabla f(x^k) - b^T \nabla f(x^k)$$

$$= (A x^k - b)^T \nabla f(x^k)$$

$$\nabla f(x^k)^T \nabla f(x^k) = \|\nabla f(x^k)\|_2^2$$

$$\Rightarrow \alpha = \frac{\|\nabla f(x^k)\|_2^2}{\nabla f(x^k)^T A \nabla f(x^k)}$$

$$(2) \text{ 收敛性收敛: } \|x^{k+1} - x^*\|_A \leq \sqrt{\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}} \|x^k - x^*\|_A$$

$$\Rightarrow \frac{\|x^{k+1} - x^*\|_A}{\|x^k - x^*\|_A} \leq \sqrt{\left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}\right)^2}$$

$\lambda_1 \ll \lambda_n$ ① 比例越大 \rightarrow 收敛速度越慢

② 比例越小 \rightarrow 收敛速度越快

与 Hessian 矩阵的 **条件数** 有关

Defn (Condition number) 对可逆矩阵 A , 其条件数为

$$\kappa(A) = \|A\| - \|A\|^{-1}$$

\rightarrow 任意范数