运筹学：科学决策的方法

建立模型 → 求解模型 → 进行决策

研究对象：最优化问题：

$$\min_{x} f(x) \quad \text{s.t. } x \in \Omega$$

→ ①解析解（闭式解）
② 数值解（算法）

基概念：① 范数 ② 凸集 ③ 梯度 ④ 凸函数

① 范数 (norm)

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

Defn: (向量范数) $\|\cdot\| : \mathbb{R}^n \to \mathbb{R}_+$

① 正定性 (positive definite)：$\forall x \in \mathbb{R}^n$, $\|x\| \geq 0$

若 $\|x\| = 0 \iff x = 0$

② 齐次性 (Homogeneity)：$\forall x \in \mathbb{R}^n$, $\alpha \in \mathbb{R}$, $\Rightarrow \|\alpha x\| = |\alpha| \cdot \|x\|$

③ 三角不等式 (triangle inequality)：$\forall x, y \in \mathbb{R}^n$ $\|x+y\| \leq \|x\| + \|y\|$

若满足上述三个条件，则称 $\|\cdot\|$ 是定义在 $\mathbb{R}^n$ 上的范数。

E.g.：A 的坐标 (x_1, y_1)，原点坐标 $(x_2, y_2) = (0, 0)$

距离：$\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$

距离：$\sqrt{x_1^2 + y_1^2}$

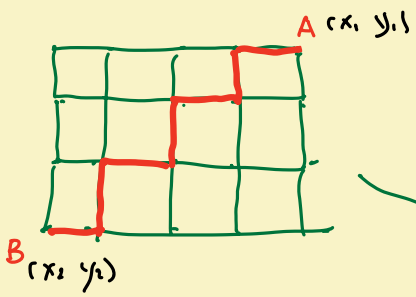

距离：$|x_1 - x_2| + |y_1 - y_2|$

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{\frac{1}{p}} \qquad \|x\|_\infty = \max_{1 \leq j \leq n} |x_j|$$

$$\|x\|_1 \leq \|x\|_2 \leq \|x\|_3 \cdots \leq \|x\|_\infty$$

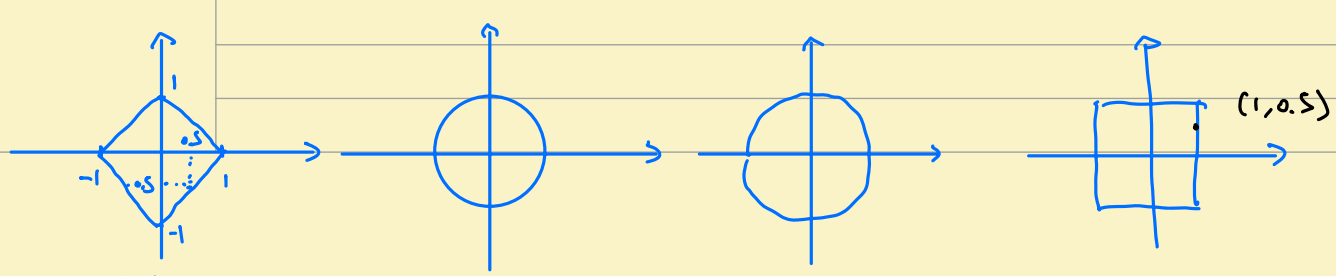

$\|x\|_1 = 1$ $\qquad$ $\|x\|_2 = 1$ $\qquad$ $\|x\|_3 = 1$ $\qquad$ $\|x\|_\infty = 1$

$$A = \begin{bmatrix} | & | & & | \\ a_1 & a_2 & \cdots & a_m \\ | & | & & | \end{bmatrix}$$

$$B = \begin{bmatrix} | & | & & | \\ b_1 & b_2 & \cdots & b_m \\ | & | & & | \end{bmatrix}$$

Prop: (Cauchy 不等式): $\forall x, y \in \mathbb{R}^n$

$$\Rightarrow |x^T y| \le \|x\|_2 \cdot \|y\|_2$$

Proof: $|\vec{x} \cdot \vec{y}| = |x^T y| = |\vec{x}| \cdot |\vec{y}| \cdot |\cos\theta|$

$$= \|x\|_2 \cdot \|y\|_2 \cdot |\cos\theta|$$

$$\le \|x\|_2 \cdot \|y\|_2$$

矩阵范数

$A \in \mathbb{R}^{n\times m}$ $B \in \mathbb{R}^{n\times m}$ $n \ne m$

$$A^T \cdot B = \begin{bmatrix} a_1 \cdot b_1 & a_1 \cdot b_2 & a_1 \cdot b_3 & \cdots & a_1 \cdot b_m \\ & & & & \\ & & & & \\ a_m \cdot b_1 & & & & a_m \cdot b_m \end{bmatrix}$$

$A^T \cdot B \ne B^T A$ $\quad A + B = B + A$

$tr(A)$ $\quad A \in \mathbb{R}^{n\times n}$

$$= \sum_{i=1}^{n} a_{ii}$$

$A, B \in \mathbb{R}^{n\times n}$ $\quad tr(AB) = tr(BA)$

$A, B, C \in \mathbb{R}^{n\times n}$ $\quad tr(ABC) = tr(CAB) = tr(CBA)$

$tr(A) = tr(A^T)$

矩阵范数: $\|A\|_1 = \sum_i \sum_j |a_{ij}|$

$\|A\|_F = \sqrt{\sum_i \sum_j |a_{ij}|^2} = \sqrt{tr(A^TA)}$

$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ $\quad \|A\|_F^2 = a_{11}^2 + a_{12}^2 + a_{21}^2 + a_{22}^2$

$A^T \cdot A = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} a_{11}^2 + a_{21}^2 & X \\ X & a_{12}^2 + a_{22}^2 \end{bmatrix}$

$tr(A^TA) = a_{11}^2 + a_{12}^2 + a_{21}^2 + a_{22}^2$

诱导 (induced) 矩阵范数: 算子范数

Defn: $A \in \mathbb{R}^{n \times m}$, 给定 d 维和 s 维空间的向量范数 $\|\cdot\|_d$ 和 $\|\cdot\|_s$, 诱导范数为

$$\|A\|_{(d,s)} = \max_{x \in \mathbb{R}^m, \|x\|_m = 1} \|Ax\|_n .$$

若 $d = s$, 记 $\|A\|_{(d,s)} = \|A\|_{(s)}$

E.g.: $n = m = 1$ $\quad \|A\|_{(1)} = \max_{\|x\|_1 = 1} \|Ax\|_1 = \max_{1 \le j \le m} \sum_{i=1}^{n} |a_{ij}|$

谱范数 → $n \times m = 2$ $\quad \|A\|_{(2)} = \max_{\|x\|_2 = 1} \|Ax\|_2 = \sqrt{\lambda_{max}(A^TA)}$

Proof: $\|Ax\|_2^2 = x^TA^TAx$ $\quad A^TAv = \lambda v \to A^TA$ 特征向量

$\to A^TA$ 特征值

$\|x\|_2 = 1$ $\quad \|Ax\|_2^2 \le \lambda_{max} x^Tx$ $\quad x = v_{max} \iff \|Ax\|_2^2 = \lambda_{max} x^Tx$

$n = m = \infty$ $\quad \|A\|_{(\infty)} = \max_{\|x\|_\infty = 1} \|Ax\|_\infty = \max_{1 \le i \le n} \sum_{j=1}^{m} |a_{ij}|$

$Ax = \begin{bmatrix} — A_1 — \\ — A_2 — \\ \vdots \\ — A_n — \end{bmatrix} \begin{bmatrix} | \\ x \\ | \end{bmatrix}$

Proof: $\|Ax\|_\infty = \max_{1 \le i \le n} \left| \sum_{j=1}^{m} a_{ij} \cdot x_j \right| = \max_{1 \le i \le n} \sum_{j=1}^{m} |a_{ij}| \cdot |x_i|$ $\quad \|x\|_\infty = 1$

$= \max_{1 \le i \le n} \sum_{j=1}^{m} |a_{ij}|$

核范数 (nuclear norm) $\|A\|_* = \sum_{i=1}^{r} \sigma_i$ ← A的奇异值

上述所有范数满足

$$\|Ax\|_{(m)} \le \|A\|_{(n,m)} \|x\|_{(m)}$$ ← 相容性

Defn: (矩阵范数)

① 正定性:

② 齐次性:

③ 三角不等式:

④ 相容性:

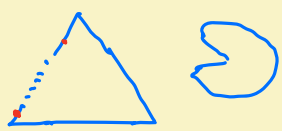

凸集 (convex set)

Defn: (凸集) C是一个集合, 如果连接集合C中的任意两点都在C内, 则称C是凸集

$$x_1, x_2 \in C \Rightarrow \theta x_1 + (1-\theta) x_2 \in C \quad \forall \theta \in [0,1]$$

仿射集 (affine set)

Defn: (仿射集) C是一个集合,

$$x_1, x_2 \in C \Rightarrow \theta x_1 + (1-\theta) x_2 \in C \quad \forall \theta \in \mathbb{R}$$

则称C是仿射集

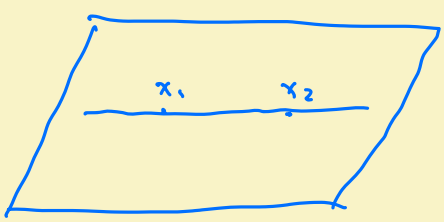

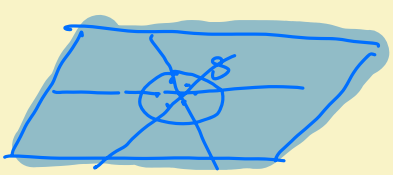

E.g.: $C = \{x \mid Ax = b\}$ ← $Ax=b$ 的解集

Proof: 取 $x_1, x_2 \in C$, 则 $Ax_1 = b$ $Ax_2 = b$

$\Rightarrow \theta Ax_1 = \theta b$ $(1-\theta)Ax_2 = (1-\theta)b$

$\Rightarrow \theta Ax_1 + (1-\theta)Ax_2 = b$

$= A(\theta x_1 + (1-\theta)x_2) = b \Rightarrow \theta x_1 + (1-\theta)x_2 \in C$

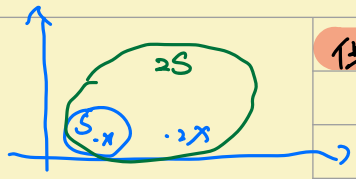

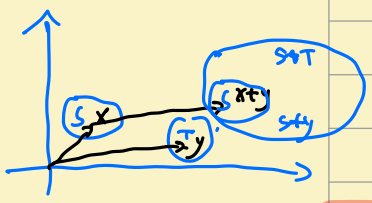

保凸运算:

① 若 S 是凸集: $\forall k\in\mathbb{R}$, $kS=\{kx \mid x\in S\}$ 是凸集

② 若 S, T 是凸集: $S+T=\{x+y \mid x\in S,\ y\in T\}$ 是凸集

③ 若 S, T 是凸集, $S\cap T$ 是凸集 → 任意凸集的交集是凸集

④ 若 S 是凸集, S的内部和闭包都是凸集

凸组合: 形如 $x=\theta_1x_1+\theta_2x_2+\cdots\theta_kx_k$

$\theta_1+\cdots\theta_k=1 \quad \theta_i\geq 0 \quad i=1,\dots k$

称点 x 为 $x_1,\dots x_k$ 的凸组合

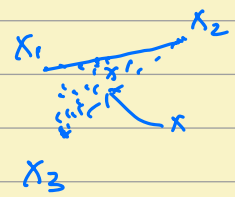

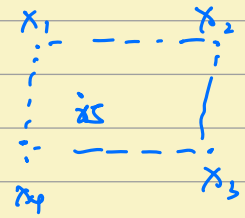

$\exists\ \theta_1\cdots\theta_4$

s.t. $x_5=\theta_1x_1+\theta_2x_2+\theta_3x_3+\theta_4x_4$

凸包: 集合 S 的所有点的凸组合构成的点集为S的凸包, 记 conv S.