

最优化算法

数学分析: Weierstrass theorem

若 $f(x)$ 在闭区间 $[a, b]$ 上连续, 则 $f(x)$ 在 $[a, b]$ 上必定取得最大值和最小值.

E.g. $f(x) = \frac{1}{x} \quad x \in [0, 1]$

$f(x) = \frac{1}{x} \quad x \in [1, +\infty]$

$f(x) = \begin{cases} 0 & x \in [0, 1] \\ +\infty & \text{otherwise} \end{cases}$

第四节课 Note

Defn (实值函数): 映射 $f: \mathbb{R}^n \rightarrow \mathbb{R}$

(广义实值函数): 映射 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}} := \mathbb{R} \cup \{+\infty\}$

(适当函数): $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}, \Omega \neq \emptyset$

① 存在 $x \in \Omega$ 使得 $f(x) < +\infty$, 且

② 存在 $x \in \Omega$, 使得 $f(x) > -\infty$

则称 f 为适当函数.

Defn (下水平集) $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}, \quad C_\alpha := \{x \mid f(x) \leq \alpha\}$ 为 f 的下水平集




Defn (上图) $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}},$

$\text{epi } f := \{(x, t) \in \mathbb{R}^{n+1} \mid f(x) \leq t\}$

Defn (闭函数) 设 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}},$ 若 $\text{epi } f$ 是闭集, 则称 f 为闭函数

Defn (下半连续函数) 设 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}},$ 若对任意 $x \in \mathbb{R}^n,$ 有

$$\liminf_{y \rightarrow x} f(y) \geq f(x)$$



Thm (下半连续函数与闭函数) 设 $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$,

以下命题等价:

- ① $f(x)$ 任意下水平集为闭集
- ② $f(x)$ 是下半连续的
- ③ $f(x)$ 是闭函数.

Note: 我们希望将 Weierstrass theorem 扩展到定义域非紧, 且称函数非连续

Thm (Weierstrass theorem) $f: \Omega \rightarrow (-\infty, +\infty]$ 适当且闭的函数, 如果以下三个条件中任意一个条件成立:

- ① $\text{dom } f = \{x \in \Omega \mid f(x) < +\infty\}$ 是有界的.
- ② 存在一个 α 下水平集: $C_\alpha = \{x \in \Omega \mid f(x) \leq \alpha\}$ 是非空且有界的
- ③ f 是强制的 (coersive): $\forall \|x^k\| \rightarrow +\infty, x^k \in \Omega$, 有 $\lim_{k \rightarrow \infty} f(x^k) = +\infty$

则优化问题:

$$\min f(x)$$

$$\text{s.t. } x \in \Omega$$

→ 有界闭集

的最小值点集: $\{x \in \Omega \mid f(x) \leq f(y) \ \forall y \in \Omega\}$ 是非空且紧的

Proof: ② ⇒ 结论. 自证法证明下水平集存在. 设下确界 $t := \inf f(x) < +\infty$ 则存在点列 $\{x^k\}_{k=1}^\infty \subset C_\alpha$ 使得 $\lim_{k \rightarrow \infty} f(x^k) = t = -\infty$. 因为 C_α 有界, 则 $\{x^k\}$ 存在一个聚点 x^* , 因为 f 是闭函数, 所以上面为闭集, 则 $(x^*, t) \in \text{epi } f \Rightarrow f(x^*) \leq t = -\infty$ 与 f 的适当性矛盾, 故 $t > -\infty$ 由于 t 是下确界, 且 $f(x^*) \leq t \Rightarrow f(x^*) = t$, 因此 C_α 是闭集, $\Rightarrow C_\alpha$ 有界 $\Rightarrow$ 最小值点集为紧集

① ⇒ ② 因为 $\text{dom } f$ 有界, 且 f 是适当函数 $\exists x_0 \in \Omega$, 使得 $f(x_0) < +\infty$, 令 $\alpha = f(x_0)$. 由于 $\text{dom } f$ 有界 $\Rightarrow C_\alpha \subset \text{dom } f$ 且有界非空 $\Rightarrow$ ② 成立.

③ ⇒ ② 假设 C_α 无界, 存在 $\{x^k\} \in C_\alpha$ s.t. $\lim_{k \rightarrow \infty} \|x^k\| = +\infty$. 根据 f 的强制性, 有 $\lim_{k \rightarrow \infty} f(x^k) = +\infty$. 由于 C_α 是下水平集 $\forall x \in C_\alpha$, 有 $f(x) \leq \alpha < +\infty$. 矛盾 $\Rightarrow$ ② 成立.

$$f(x) = x$$

Note: ① 2个条件都互保证 $f(x)$ 的最小值不会在无穷远处取得
② 可行域可以无界, 只需要(2): 下水平集非空有界, $f(x)$ 适当闭

E.g.: 判断下列目标函数的优化问题的最小值点集是否非空且紧

① $f(x) = x^2 \quad x \in \mathbb{R} \quad \leftarrow f$ 是强制的

② $f(x) = -e^{-x} \quad \leftarrow$ 任意下水平集无界

③ $f(x) = I_{(0,1)} := \begin{cases} 0 & x \in (0,1) \\ +\infty & \text{otherwise} \end{cases} \quad \leftarrow \text{dom} f = (0,1) \text{ 有界}$

无约束优化算法

Defn (迭代算法) 从一个初始点 x_0 出发, 按照某种特定规则进行迭代, 得到一个序列 $\{x^k\}$, 如果迭代有限步终止, 那么希望最后一个点是优化问题的解.

① 迭代: E.g. 梯度搜索算法: $x^{k+1} = x^k + \alpha^k \phi^k$

② 终止条件 (收敛准则):

E.g. 常用 $\frac{f(x^k) - f^*}{\max\{|f^*|, 1\}} \leq \varepsilon_1, \quad \|\nabla f(x^k)\| \leq \varepsilon_2$

$$\frac{\|x^{k+1} - x^k\|}{\max\{\|x^k\|, 1\}} \leq \varepsilon_3, \quad \frac{\|f(x^{k+1}) - f(x^k)\|}{\max\{\|f(x^k)\|, 1\}} \leq \varepsilon_4$$

如何评价的效果?

① 比较不同算法最优值的大小

② 最优值唯一, 比较不同算法的收敛速率

收敛速率

对一个算法, $\{x^k\}$ 满足 $\lim_{k \rightarrow \infty} \|x^k - x^*\| = 0$, 且 x^* 是一个极小解
则算法是收敛到收敛到极小解

Q: Quotient

Q - 收敛速度

$$Q - \text{线性收敛}: \lim_{k \rightarrow +\infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \leq \alpha \quad \alpha \in (0, 1)$$

$$Q - \text{超线性收敛}: \lim_{k \rightarrow +\infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 0$$

$$Q - \text{一次线性收敛}: \lim_{k \rightarrow +\infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 1$$

$$Q - \text{二次收敛}: \lim_{k \rightarrow +\infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^2} \leq \beta \quad \beta > 0$$

梯度搜索方法

$$\text{迭代 (Iterate)} \quad x^{k+1} = x^k + \alpha^k d^k$$

d^k : 搜索方向. α^k : 步长 ($\alpha > 0$) (机器学习: 学习率)

考虑 $\phi(\alpha) = f(x^k + \alpha d^k)$. 迭代时, 希望目标值下降:

$$f(x^{k+1}) < f(x^k)$$

$$\Leftrightarrow f(x^k + \alpha^k d^k) \leq f(x^k)$$

$$\begin{aligned} \phi(\alpha) &= f(x^k + \alpha d^k) && \text{Taylor 展开至 } x^k \text{ 处} \\ &= f(x^k) + \nabla f(x^k)^T (x^k + \alpha d^k - x^k) + o(\alpha^2 \|d^k\|^2) \\ &= f(x^k) + \alpha \nabla f(x^k)^T d^k + o(\dots) \end{aligned}$$

要使 $f(x^{k+1}) < f(x^k)$, 令 $\nabla f(x^k)^T d^k < 0$ 即可

Defn (下降方向) 对于可微函数 f , 如果存在向量 d 满足

$$\nabla f(x)^T d < 0$$

那么称 d 为 f 在点 x 处的一个下降方向.

Note: 当 $d^k = -\nabla f(x^k)$, 令使得函数的下降速度最快

称为最速下降法/梯度下降法

$$x^{k+1} = x^k - \alpha^k \nabla f(x^k)$$

$$\text{下降量: } f(x^{k+1}) - f(x^k) \approx \alpha \cdot \|\nabla f(x^k)\|^2$$

精确搜索步长:

$$\alpha^k = \arg \min_{\alpha \geq 0} \phi(\alpha) = f(x^k + \alpha d^k)$$

① 计算量大, 实际中很少用

② 实际用非精确搜索步长.

Thm (二次正定梯度下降) 考虑 $f(x) = \frac{1}{2} x^T A x - b^T x$, $A > 0$

$$\text{① 精确搜索步长: } \alpha^k = \|\nabla f(x^k)\|_2^2 / \nabla f(x^k)^T A \nabla f(x^k)$$

$$\text{② } Q\text{-线性收敛: } \|x^{k+1} - x^*\|_A \leq \sqrt{\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}} \|x^k - x^*\|_A$$

其中 λ_1, λ_n 对应 $\min, \max$ eigenvalue of A , $\|x\|_A = \sqrt{x^T A x}$

$$\text{Proof: 梯度: } \nabla f(x^k) = Ax^k - b$$

$$\text{步长: } \alpha^k = \arg \min_{\alpha \geq 0} \phi(\alpha)$$

$$\text{迭代: } x^{k+1} = x^k - \alpha^k \nabla f(x^k)$$

$$Q \quad f(x, y) = (x-1)^2 + (y-2)^2$$

步长: $\alpha = 0.5 \rightarrow$ 最优

$\alpha \geq 1 \rightarrow$ 不收敛

Claim: ① 当步长取 $\frac{1}{L}$ 时, 速度最快 L 是 f 的梯度 Lipschitz 常数

梯度 Lipschitz 连续: $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$

$$\nabla f(x, y) = \begin{pmatrix} 2(x-1) \\ 2(y-2) \end{pmatrix} \quad \begin{matrix} u = (x_1, y_1) \\ v = (x_2, y_2) \end{matrix}$$

$$\begin{aligned} \|\nabla f(u) - \nabla f(v)\| &= \left\| 2 \begin{pmatrix} x_1 - x_2 \\ y_1 - y_2 \end{pmatrix} \right\| \leq 2 \left\| \begin{pmatrix} x_1 \\ y_1 \end{pmatrix} - \begin{pmatrix} x_2 \\ y_2 \end{pmatrix} \right\| \\ &= 2\|u - v\| \end{aligned}$$

$L = 2 \rightarrow$ 最优步长 $\alpha = \frac{1}{L} = \frac{1}{2}$

Claim: 若梯度 Lipschitz 常数为 L , 梯度下降稳定步长为 $0 < \alpha < \frac{2}{L}$

梯度下降法: $\underline{z^{k+1} = z^k - \alpha \nabla f(z^k)}$

$$z^k = \begin{pmatrix} x^k \\ y^k \end{pmatrix}, \quad z^* = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$\nabla f(z^k) = 2(z^k - z^*)$$

$$z^{k+1} = z^k - 2\alpha (z^k - z^*)$$

$$\Rightarrow z^{k+1} - z^* = (1-2\alpha)(z^k - z^*)$$

$$= \frac{\|z^{k+1} - z^*\|}{\|z^k - z^*\|} = |1-2\alpha| < 1$$

$$\Rightarrow -1 < 1-2\alpha < 1 \Rightarrow 0 < \alpha < 1$$

3. 梯度下降法的收敛速度与 $f(x)$ 的 Hessian 矩阵的条件数有关 $A = \nabla^2 f(x, y)$

Defn (条件数) 对于可逆矩阵 A , 条件数为

$$\kappa(A) = \|A\| - \|A\|^{-1}$$

$$\Leftrightarrow \frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n}$$

考虑 λ_1 与 λ_n 的比例:

① 比例越大 $\rightarrow$ 收敛速度越慢


② 比例越小 $\rightarrow$ 收敛速度越快

$$\text{考虑 } f(x, y) = x^2 + 10y^2 \quad \nabla^2 f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 20 \end{pmatrix}$$

$$\lambda_1 = 20$$

$$\lambda_2 = 2$$

条件数小 $\Rightarrow$



$\Leftarrow$ 条件数大